Detección, segmentación y medición de fracturas pélvicas en CT

Proyecto Corte 2 · Estefania Hernández, Natalia Paredes, Mariana Cifuentes y John Franco · Universidad Autónoma de Occidente · 12 de octubre de 2026

Resumen

Se desarrolló y evaluó un sistema multitarea para la detección, segmentación, clasificación anatómica y medición de separaciones entre fragmentos pélvicos en tomografías computarizadas del conjunto PENGWIN. Se compararon dos configuraciones entrenadas sin aprendizaje por transferencia: SE y una variante con atención CBAM. En 15 casos de prueba, CBAM mejoró ligeramente el Dice por fragmento (0,9520 frente a 0,9505) y mAP@0,50 (0,9376 frente a 0,9293). Sin embargo, ambas configuraciones presentaron dificultades para estimar la separación entre fragmentos, particularmente cuando la distancia real superaba 2 mm. Se analizan las decisiones arquitectónicas, los aciertos, los casos de fallo y las limitaciones de la evaluación.

Introducción

La identificación de fracturas pélvicas mediante CT requiere localizar estructuras óseas, distinguir fragmentos individuales y estimar sus separaciones físicas. Para abordar estas tareas, se implementó un sistema propio sobre PENGWIN, con resultados integrados en visualizadores 2D y 3D. Este informe analiza las decisiones que motivaron su diseño y evalúa sus consecuencias mediante una comparación entre CBAM y SE con las anotaciones de referencia y análisis de errores.

Metodología y decisiones de diseño

Selección de arquitectura. Se eligió U-Net 3D porque los cinco equipos mejor posicionados en la tarea de CT de PENGWIN 2024 emplearon variantes de esta arquitectura o sus derivadas, principalmente en estrategias de segmentación anatómica y de fragmentos (Sang et al., 2025). Su estructura encoder-decoder con conexiones de salto permite combinar contexto volumétrico y detalles espaciales. Se optó por un backbone compartido para integrar las tareas de detección, segmentación y clasificación, incorporando CBAM para evaluar el beneficio de la atención espacial y por canales (Woo et al., 2018). La detección con anclas, el NMS y las demás cabezas son implementaciones propias entrenadas desde cero; la cabeza de máscara se inspira en Mask R-CNN, sin usar su framework ni pesos preentrenados.

Incorporación de la cabeza de máscara. Se agregó una cabeza específica por ROI porque identificar los tres huesos no garantiza distinguir sus fragmentos. Esta salida busca delimitar regiones locales con mayor precisión, reducir predicciones fuera de la región de interés y proporcionar máscaras para estimar posteriormente la separación física entre fragmentos.

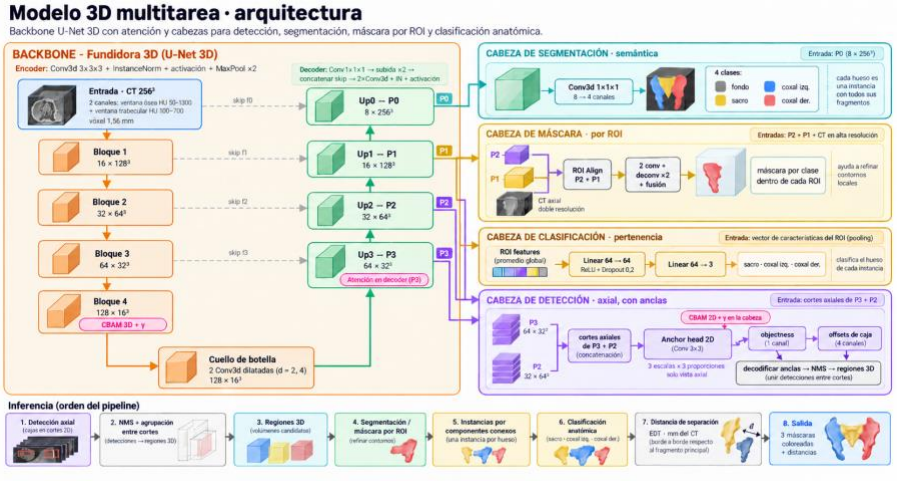
Calibración del entrenamiento. El entrenamiento de redes neuronales se fundamenta en la minimización de funciones de pérdida mediante optimización (Raff, 2022). Cada coeficiente se calculó como λ = prioridad / pérdida inicial, con la pérdida inicial medida en 10 CT de entrenamiento con el modelo sin entrenar; así cada tarea aporta al inicio su prioridad, sin depender de la escala de su pérdida. Las prioridades fueron 2 para segmentación y máscara y 1,5 para detección y clasificación: λ_{det} = 1,0833; λ_{clas} = 1,3601; λ_{seg} = 1,2345. Se mantuvieron iguales en ambas configuraciones. La ablación comparó CBAM, sin transfer learning, utilizando los checkpoints de las épocas 140 (SE) y 130 (CBAM), aunque ambos se entrenaron durante 140 épocas.

Ecuación 1. Función de pérdida total ponderada del modelo multitarea.

$$\mathcal{L}_{total} = \lambda_{det}\mathcal{L}_{det} + \lambda_{clas}\mathcal{L}_{clas} + \lambda_{seg}\mathcal{L}_{seg}$$

Nota. Los coeficientes λ ponderan las pérdidas de detección, clasificación anatómica y segmentación.

Figura 1. Arquitectura general y ubicación del bloque de atención.



Nota. La estimación de separación corresponde a una etapa de postprocesamiento

Resultados y estudio de ablación

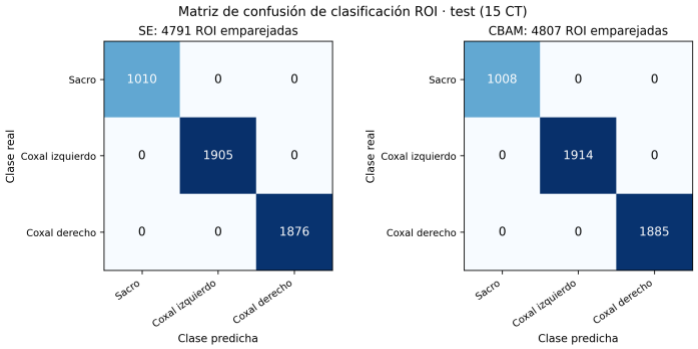
La comparación se realizó sobre el conjunto de prueba de 15 CT por configuración, utilizando las evaluaciones finales.

Tabla 1. Comparación de desempeño entre SE y CBAM en el conjunto de prueba.

Métrica	SE	Con CBAM
Dice por fragmento	0,9505	0,9520
IoU por fragmento	0,9063	0,9089
Detección raw: mAP@0,50	0,9293	0,9376
F1 macro clasificación ROI	1,0000	1,0000
MAE separación global (mm)	1,8085	1,8126
MAE si GT > 2 mm (mm)	11,5912	9,6706

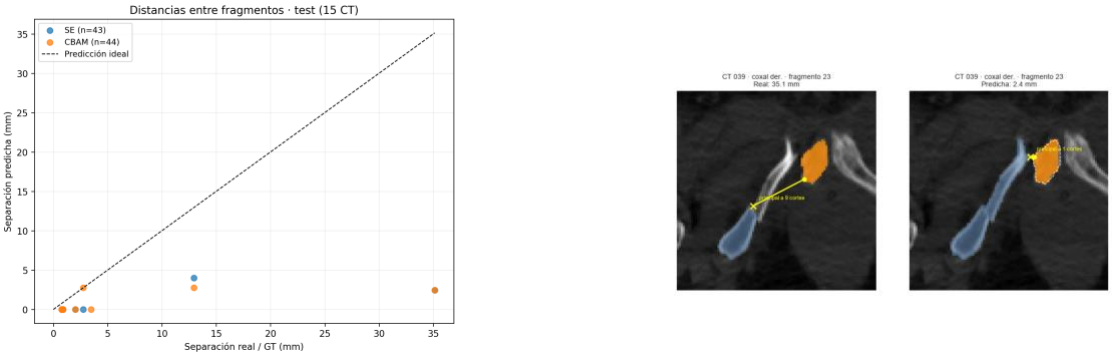
La incorporación de CBAM produjo mejoras ligeras en segmentación anatómica (+0,0015 Dice por fragmento) y detección (+0,0083 mAP@0,50). Ambos modelos alcanzaron un F1 macro de 1,0 en clasificación ROI, debido a que la evaluación considera únicamente regiones predichas con correspondencia válida (IoU ≥ 0,5), las cuales fueron clasificadas correctamente. No obstante, esto no implica una identificación perfecta de todos los fragmentos. Aunque CBAM no redujo el MAE global de separación, obtuvo un menor error para distancias reales superiores a 2 mm (9,67 frente a 11,59 mm), sobre solo 5 fragmentos. Se seleccionó CBAM como modelo final por sus ventajas en detección y segmentación, aunque en validación ambos quedaron empatados (0,907 y 0,906).

Figura 2. Matriz de confusión de clasificación anatómica en prueba.



Ambos modelos clasificaron correctamente todas las regiones anatómicas con correspondencia válida: 4807 en CBAM y 4791 en SE, sin confusiones entre sacro, coxal izquierdo y coxal derecho. Sin embargo, el F1 macro de 1,0 se limita a estas regiones emparejadas y no demuestra una detección o segmentación perfecta: 448 de las 5.255 cajas predichas por CBAM (8,5 %) no tienen una región real correspondiente y quedan fuera del F1.

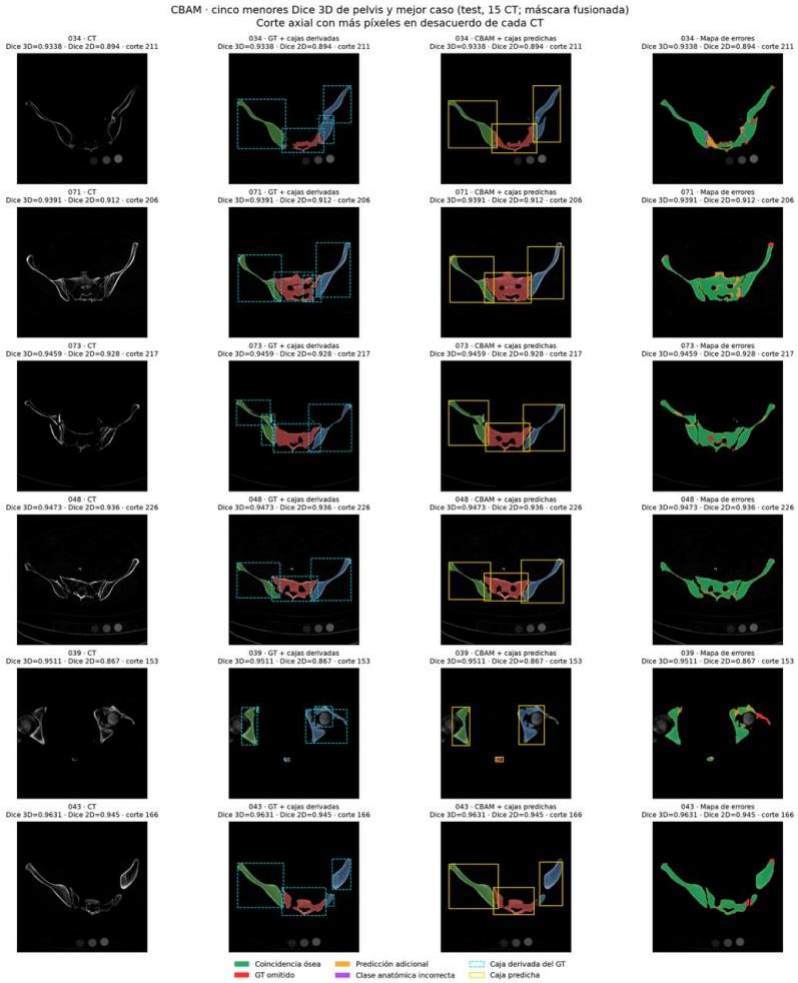
Figura 3. Separación predicha frente a ground truth en milímetros.



En ambas configuraciones, las predicciones se concentran cerca de cero y se alejan de la diagonal de referencia cuando aumenta la separación real, lo que evidencia una tendencia a subestimar las distancias mayores. En el caso 039, CBAM subestimó la separación del fragmento 23 del coxal derecho (2,44 mm frente a 35,12 mm reales). La visualización sugiere una delimitación o asociación incorrecta con el fragmento principal, cuya proximidad aparente aumentó en la predicción. Esto evidencia cómo los errores de segmentación por instancia pueden propagarse al cálculo de distancias, incluso cuando la región anatómica se clasifica correctamente.

Análisis de errores y discusión

Figura 4. Comparación de los cinco casos con menor Dice 3D de pelvis y el mejor caso del modelo CBAM en test.



Los cinco casos con menor Dice fueron 034 (0,9338), 071 (0,9391), 073 (0,9459), 048 (0,9473) y 039 (0,9511), mientras que el mejor fue 043 (0,9631). En los mapas de errores, el verde indica segmentación correcta; el rojo, regiones óseas omitidas; el naranja, predicciones adicionales; y el morado, clases anatómicas incorrectas. Las cajas celestes discontinuas corresponden al ground truth derivado y las amarillas, a las detecciones del modelo. En los casos de menor Dice predominan las omisiones (rojo) y las predicciones adicionales (naranja), principalmente en contornos y regiones pequeñas, posiblemente por dificultades para delimitar estructuras óseas complejas. El caso 043 presenta mayor concordancia. En conclusión, CBAM logra una buena segmentación global, pero los errores locales pueden comprometer la individualización de fragmentos y las mediciones de separación.

Conclusiones

La evaluación evidenció que una alta precisión en segmentación anatómica y detección no garantiza la correcta individualización de fragmentos ni mediciones fiables de separación. Aunque CBAM mostró algunas ventajas frente a SE, los errores observados señalan la necesidad de mejorar la segmentación por instancia y la consistencia geométrica.

Referencias

Raff, E. (2022). *Inside deep learning: Math, algorithms, models*. Manning Publications.

Sang, Y., et al. (2025). *Benchmark of segmentation techniques for pelvic fracture in CT and X-ray: Summary of the PENGWIN 2024 challenge*. arXiv. https://arxiv.org/abs/2504.02382

Woo, S., Park, J., Lee, J.-Y., & Kweon, I. S. (2018). CBAM: Convolutional block attention module. *Proceedings of the European Conference on Computer Vision (ECCV)*, 3–19. https://doi.org/10.1007/978-3-030-01234-2_1