PelvicU-3D-CBAM

Model Card

Información del modelo

PelvicU-3D-CBAM es un modelo de investigación académica que analiza tomografías computarizadas (CT) de pelvis para localizar regiones óseas, segmentar el sacro y los huesos coxales, clasificar anatómicamente las regiones detectadas y estimar distancias entre fragmentos y el hueso principal mediante procesamiento posterior. Esta variante utiliza un mecanismo de atención Convolutional Block Attention Module (CBAM); la variante complementaria del proyecto emplea atención squeeze-and-excitation (SE).

Descargo de responsabilidad: No constituye un dispositivo médico, no cuenta con validación clínica y no debe utilizarse para tomar decisiones diagnósticas o quirúrgicas.

Descripción del modelo

La entrada es un volumen de 256 × 256 × 256 vóxeles, correspondiente a un campo de visión de 400 mm y orientación LPS. El procesamiento contempla dos representaciones de intensidad: ventana ósea (50 a 1300 HU) y ventana trabecular (100 a 700 HU).

El backbone es una U-Net 3D, con encoder de 16, 32, 64 y 128 canales, cuello de botella de 128 canales y decoder de 64, 32, 16 y 8 canales. Según la configuración documentada, el CBAM 3D residual está habilitado en el cuarto bloque del encoder (E4); también hay atención configurada en P3 del decoder y en la cabeza de detección. El mecanismo CBAM combina atención por canales y atención espacial; su contribución residual es regulada por un parámetro aprendible γ, inicializado en cero.

Las salidas del modelo son:

- **Detección axial 2D:** localiza regiones mediante cajas por corte.
- **Segmentación semántica:** asigna cada vóxel a una de cuatro clases (fondo, sacro, coxal izquierdo o coxal derecho).
- **Máscara por ROI:** refina la máscara de una región propuesta.
- **Clasificación anatómica:** identifica si la región corresponde al sacro, al coxal izquierdo o al derecho.

La distancia de separación se estima como posprocesamiento de las máscaras; no es una quinta cabeza de predicción.

Desarrollado por: Estefanía Hernández, John David Franco, Mariana Cifuentes y Natalia Paredes.

Tipo de modelo: red convolucional multitarea U-Net 3D con atención CBAM.

Recursos del modelo

Repositorio: https://github.com/HEstefaniaR/proyecto2-analitica-de-datos

Demo: dashboard en Streamlit incluido en el repositorio (carpeta dashboard/).

Implementación: src/models/model3d.py

Checkpoint: results/detection/unet3d_cbam_trab/best.pth

Configuración: results/detection/unet3d_cbam_trab/config.json

Usos

Uso previsto

Investigación académica de visión por computador aplicada al análisis de CT pélvica, incluida la localización, segmentación, clasificación anatómica y estimación geométrica de separación de fragmentos. Los resultados permiten estudiar el comportamiento de esta variante del modelo, pero no constituyen evidencia de utilidad clínica.

Fuera de alcance

No constituye un dispositivo médico, no ha sido validado clínicamente y no debe utilizarse para apoyar decisiones quirúrgicas reales.

No funciona con CT que no traen la pelvis completa, porque no fue entrenado con estudios parciales.

No separa fragmentos del mismo hueso: el modelo entrega una máscara por hueso.

No se probó con pelvis sin fracturas, con implantes metálicos, con otros huesos ni con otras modalidades (resonancia, radiografía).

Sesgos

Se trabajó con 100 CT de un conjunto público. No se dispone de una evaluación por grupos demográficos ni de validación multicéntrica externa; por tanto, no puede asegurarse que el modelo generalice a otras poblaciones, escáneres o condiciones de adquisición.

Limitaciones

El conjunto de prueba tiene 15 CT, un tamaño insuficiente para establecer seguridad clínica. El Dice alto de segmentación no garantiza que todas las fracturas sean reconocidas ni que se conserven separaciones muy pequeñas. La estimación geométrica depende de la precisión de las máscaras y de las correspondencias de fragmentos. En particular, aunque el error absoluto medio

global de distancia fue 1,778 mm, para los 5 fragmentos de prueba con separación real mayor de 2 mm alcanzó 11,207 mm.

Cómo usar el modelo

El repositorio incluye el código y los pesos para reconstruir la variante CBAM. Ejemplo de carga del checkpoint:

```
import torch

from src.models.model3d import load_checkpoint, load_model

path = "results/detection/unet3d_cbam_trab/best.pth"

device = torch.device("cuda" if torch.cuda.is_available() else "cpu")

ckpt = load_checkpoint(path)

model = load_model(ckpt, device)

model.eval()
```

Para realizar inferencia sobre CT deben aplicarse primero la orientación, el remuestreo, el ventaneo y los demás pasos del pipeline. La carga anterior por sí sola no procesa un archivo NIfTI o DICOM. Véanse src/dataset/preprocessing.py, src/inference.py y src/models/model3d.py.

Información del entrenamiento

Se utilizó AdamW, tasa de aprendizaje inicial 0,001, *weight decay* 0,01, planificación coseno, recorte de gradiente 10,0 y semilla 99. Se configuraron 140 épocas, lote de 1 CT, precisión mixta habilitada en la configuración y aumentos de datos de rotación, escala, desplazamiento, contraste, brillo, ruido y degradación de resolución. La pérdida multitarea combina componentes de detección, anatomía, segmentación y máscara. La segmentación utiliza Cross Entropy + Dice, con pesos 0,5 y 0,5, y supervisión auxiliar con peso 0,5.

Checkpoint evaluado: época 130. No se utilizó transfer learning.

Datos de entrenamiento

PENGWIN (CT pélvicas): 100 casos con anotaciones de estructuras óseas y fragmentos. División fija por caso: 70 entrenamiento, 15 validación y 15 prueba, evitando mezclar cortes de un mismo caso entre particiones.

Preprocesamiento

Reorientación a LPS, definición de un campo de visión de 400 mm y remuestreo a 256 × 256 × 256. Se aplican ventana ósea [50, 1300] HU y ventana trabecular

[100, 700] HU. Para el procesamiento de máscaras ROI se contempla una caché de mayor resolución axial (256 × 512 × 512).

Velocidad, tamaños y tiempos

Se entrenó por 140 épocas con una GPU NVIDIA RTX 3060 de 6 GB. El entrenamiento duró 5,8 horas (unos 2,5 minutos por época) y usó 3,9 GB de memoria en el pico. Se guardó la época con el mejor promedio en validación de mAP@0.50:0.95, Dice semántico, Dice de máscara y F1 macro (época 130). El modelo tiene 1,87 millones de parámetros. La inferencia tarda 1,38 s por CT en GPU y 12,1 s en CPU.

Evaluación

Se evaluó la variante CBAM en 15 CT de validación y 15 CT de prueba. Las métricas proceden de results/detection/unet3d_cbam_trab/eval/metrics.json, según la versión de resultados documentada en este Model Card. En detección se reportan las cajas de la cabeza y, aparte, las cajas ajustadas a la segmentación (margen de 2 px elegido en validación).

Métricas

El Dice mide solapamiento de máscaras; mAP e IoU medio evalúan cajas de detección; F1 macro mide clasificación anatómica; y MAE indica el error absoluto medio en la distancia estimada en milímetros.

Tarea	Métrica	Validación (15 CT)	Prueba (15 CT)
Segmentación semántica	Dice macro	0,955	0,952
	IoU macro	0,915	0,909
	HD95 (mm)	2,47	2,12
	ASSD (mm)	0,53	0,53
Cabeza de máscara	Dice macro	0,952	0,950
Detección	mAP@0.50	0,929	0,938
	mAP@[0.50:0.95]	0,707	0,686
	IoU medio de las cajas	0,875	0,861
	mAP@[0.50:0.95] con cajas ajustadas (2 px)	0,814	0,816
Clasificación	F1 macro / AUC macro	1,00 / 1,00	1,00 / 1,00

Distancia entre fragmentos	Error absoluto medio, semántica (mm)	4,17	1,81
	Error absoluto medio, fusión (mm)	3,87	1,78
	Error si la distancia real > 2 mm, semántica (mm)	31,2	9,67

Segmentación por hueso

Hueso	Dice	IoU	HD95 (mm)	ASSD (mm)
Sacro	0,937	0,883	2,83	0,66
Coxal izquierdo	0,958	0,919	1,83	0,49
Coxal derecho	0,961	0,925	1,69	0,46

Resumen de los resultados

En el conjunto de prueba, la variante CBAM logró un Dice semántico medio por hueso de 0,952, mAP@0.50 de 0,938 (0,959 con las cajas ajustadas) para la detección axial refinada y F1 macro de 1,000 para la clasificación anatómica. El F1 no debe interpretarse como exactitud en el diagnóstico de fracturas. En la estimación de distancias, el MAE de fusión de 1,778 mm debe interpretarse con cautela por el aumento del error en los fragmentos con separación superior a 2 mm.

Referencias

- PENGWIN: Pelvic Bone Fragments with Injuries Segmentation Challenge. MICCAI 2024. https://pengwin.grand-challenge.org
- Woo, S., Park, J., Lee, J.-Y., & Kweon, I. S. (2018). *CBAM: Convolutional Block Attention Module*. European Conference on Computer Vision (ECCV), 3–19. https://doi.org/10.1007/978-3-030-01234-2_1
- Çiçek, Ö., Abdulkadir, A., Lienkamp, S. S., Brox, T., & Ronneberger, O. (2016). *3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation*. Medical Image Computing and Computer-Assisted Intervention (MICCAI), 424–432. https://doi.org/10.1007/978-3-319-46723-8_49
- Sang, Y., et al. (2026). *Benchmark of Segmentation Techniques for Pelvic Fracture in CT and X-ray: Summary of the PENGWIN 2024 Challenge*. IEEE Transactions on Medical Imaging, 45(5), 2212–2228. https://doi.org/10.1109/TMI.2025.3650126
- Jafarpoor Nesheli, S., et al. (2025). *Transformer-based and CNN-based models for clinically effective 2D and 3D pelvic bone segmentation in CT imaging*. BMC Musculoskeletal Disorders. https://doi.org/10.1186/s12891-025-09444-8

Autores del Model Card

Natalia Paredes, Mariana Cifuentes, Estefanía Hernández, John David Franco.