PelvicU-3D-SE

Model Card

Información del modelo

PelvicU-3D-SE es un modelo para tomografías computarizadas de fracturas de pelvis que permite detectar, segmentar y clasificar el sacro, el coxal izquierdo y el coxal derecho, además de medir la separación entre los fragmentos y el hueso principal. A diferencia del modelo PelvicU-3D-CBAM, usa atención squeeze-excitation (SE) en lugar de CBAM; todo lo demás es igual.

Descargo de responsabilidad: No constituye un dispositivo médico, no ha sido validado clínicamente y no debe utilizarse para apoyar decisiones quirúrgicas reales.

Descripción del modelo

La entrada del modelo es un cubo de 256x256x256 vóxeles (400 mm de lado, 1,56 mm por vóxel) con orientación LPS y dos canales: ventana ósea (50 a 1300 HU) y ventana trabecular (100 a 700 HU). El segundo canal es calculado por la red a partir del primero.

Cuenta con un backbone tipo U-Net 3D con encoder de 16, 32, 64 y 128 canales, un cuello de botella con dos convoluciones dilatadas y un decoder de cuatro niveles (P3 a P0). Tiene bloques squeeze-excitation en el bloque 4 del encoder, en el nivel P3 del decoder y en la cabeza de detección con gamma aprendible.

La cabeza de detección 2D procesa cada corte axial con 9 anclas y NMS; la cabeza de segmentación semántica clasifica cada vóxel en 4 clases (fondo, sacro, coxal izquierdo y coxal derecho), con la cabeza auxiliar en P1 solo durante el entrenamiento; la cabeza de máscara por región cuenta con ROI Align de cada caja a 48x48 y máscara de 96x96 sobre el CT; por último, la cabeza de clasificación decide a qué hueso pertenece cada caja.

Desarrollado por: Estefanía Hernández, John David Franco, Mariana Cifuentes y Natalia Paredes.

Tipo de modelo: red convolucional 3D (tipo U-Net) con cuatro salidas: detección, segmentación semántica, máscara por región y clasificación.

Recursos del modelo

Repositorio: https://github.com/HEstefaniaR/proyecto2-analitica-de-datos

Demo: dashboard en Streamlit incluido en el repositorio (carpeta dashboard/).

Implementación: src/models/model3d.py

Checkpoint: results/detection/unet3d_se_trab/best.pth

Configuración: results/detection/unet3d_se_trab/config.json

Usos

Uso previsto

Proyecto académico para estudiar la segmentación de fracturas de pelvis en CT y para comparar la atención SE con CBAM.

Fuera de alcance

No constituye un dispositivo médico, no ha sido validado clínicamente y no debe utilizarse para apoyar decisiones quirúrgicas reales.

No funciona con CT que no traen la pelvis completa, porque no fue entrenado con estudios parciales.

No separa fragmentos del mismo hueso: el modelo entrega una máscara por hueso.

No se probó con otros huesos ni con otras modalidades (resonancia, radiografía).

Sesgos

Se utilizaron 100 CT de un solo conjunto público para el entrenamiento, la validación y el test, por lo que los resultados pueden variar con otros escáneres, protocolos o poblaciones.

No se utilizaron pelvis sin fracturas ni con implantes metálicos.

Limitaciones

Los fragmentos que entran en contacto en la superficie de fractura pueden fusionarse en una sola región por errores de segmentación: el modelo entrega una máscara por hueso y los fragmentos se separan después por componentes conexos, así que dos fragmentos que se tocan quedan unidos y su distancia predicha es 0.

El error de medición de la distancia es de 1,8 mm en promedio, pero sube a 11,6 mm en los 5 fragmentos separados más de 2 mm, porque el vóxel mide 1,56 mm y una separación de pocos milímetros casi desaparece.

No hay un post procesamiento que quite regiones pequeñas lejos del hueso; en un CT de prueba (040) una región suelta eleva el HD95 del coxal izquierdo.

Cómo usar el modelo

Utilizando el código del repositorio puede correr la validación y el test usando el comando a continuación:

uv run python -m src.models.model3d evaluate --run unet3d_se_trab --attention se

Para la inferencia sobre un CT (.mha, .nii, .nii.gz o carpeta DICOM):

uv run python -m src.models.model3d infer ruta/al/ct.nii.gz --run unet3d_se_trab

Información del entrenamiento

Se utilizó el optimizador AdamW, tasa de aprendizaje 1×10^{-3}, weight decay 0,01, planificador coseno hasta 0, lote de 1 CT por paso con 32 cortes axiales para la detección, precisión mixta y aumento de datos (rotación de $\pm 10°$, escala, desplazamiento, brillo, contraste, gamma, ruido y degradación de la resolución). Se usó recorte de gradiente 10 y semilla 99. La segmentación usa entropía cruzada + Dice (pesos 0,5 y 0,5) y una salida auxiliar en P1 con peso 0,5.

Los pesos de la pérdida se calibraron con: $\lambda = \frac{prioridad}{pérdida\ inicial}$. La prioridad de la segmentación y de la máscara es 2, y la de la clasificación y la detección es 1,5.

Checkpoint evaluado: época 140. No se utilizó transfer learning.

Datos de entrenamiento

PENGWIN (tarea 1, CT): 100 tomografías de pelvis con fractura y máscaras del sacro, el coxal izquierdo, el coxal derecho y sus fragmentos. El conjunto se dividió en 70/15/15 CT, de manera estratificada por tipo de fractura y por paciente.

Preprocesamiento

Reorientación a LPS, recorte de un cubo de 400 mm centrado en la pelvis, remuestreo a 256x256x256 y ventana de 50 a 1300 HU. Además, se guarda una copia a 512x512 en el plano axial para la cabeza de máscara.

Velocidad, tamaños y tiempos

Se entrenó por 140 épocas con una GPU NVIDIA RTX 3060 de 6 GB. El entrenamiento duró 5,7 horas (2 minutos por época aproximadamente) y usó 3,9 GB de memoria en el pico. Se guardó la época con el mejor promedio en validación de mAP@0.50:0.95, Dice semántico, Dice de máscara y F1 macro. El modelo tiene 1,87 millones de parámetros. La inferencia tarda 1,38 s por CT en GPU y 11,8 s en CPU.

Evaluación

Se evaluó sobre los 15 CT de prueba, que no se usaron para entrenar ni validar. El Dice es volumétrico y por hueso.

Métricas

Dice e IoU miden el solapamiento entre la máscara predicha y la real; HD95 y ASSD, la distancia entre sus superficies en milímetros. mAP e IoU medio evalúan las cajas de la detección por corte. F1 y AUC evalúan la clasificación sobre las cajas que coinciden con un hueso real. El error absoluto medio compara la distancia predicha y la real entre cada fragmento y su hueso principal.

Tarea	Métrica	Validación (15 CT)	Prueba (15 CT)
Segmentación semántica	Dice macro	0,955	0,951
	IoU macro	0,915	0,906
	HD95 (mm)	2,63	6,88
	ASSD (mm)	0,55	0,79
Cabeza de máscara	Dice macro	0,953	0,948
Detección	mAP@0.50	0,919	0,929
	mAP@[0.50:0.95]	0,707	0,683
	IoU medio de las cajas	0,874	0,860
	mAP@[0.50:0.95] con cajas ajustadas (2 px)	0,806	0,811
Clasificación	F1 macro / AUC macro	1,00 / 1,00	1,00 / 1,00
Distancia entre fragmentos	Error absoluto medio (mm)	4,11	1,81
	Error si la distancia real > 2 mm (mm)	30,7	11,6

Segmentación por hueso

Hueso	Dice	IoU	HD95 (mm)	ASSD (mm)
Sacro	0,936	0,879	3,2	0,69
Coxal izquierdo	0,954	0,912	15,8	1,22
Coxal derecho	0,962	0,927	1,6	0,45

Resumen de los resultados

SE y CBAM quedan casi iguales: en prueba, Dice macro 0,951 frente a 0,952, mAP@0.50 0,929 frente a 0,938 y el mismo error de distancia (1,81 mm). Las diferencias son de milésimas y con 15 CT no alcanzan para decir que una atención sea mejor.

La diferencia visible está en el HD95 (6,9 mm frente a 2,1 mm).

La clasificación es perfecta sobre las 4.791 cajas que coinciden con un hueso real. El 7,9 % de las cajas predichas no coincide con ninguno.

En validación el modelo llega a Dice 0,967 y mAP@[0.50:0.95] 0,706, cerca de los valores de entrenamiento (0,968 y 0,726), así que no hay un sobreajuste notable.

Referencias

- PENGWIN: Pelvic Bone Fragments with Injuries Segmentation Challenge. MICCAI 2024. https://pengwin.grand-challenge.org
- Hu, J., Shen, L. y Sun, G. Squeeze-and-Excitation Networks. CVPR 2018.
- Çiçek, Ö. et al. 3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation. MICCAI 2016.
- Sang, Y., et al. (2026). *Benchmark of Segmentation Techniques for Pelvic Fracture in CT and X-ray: Summary of the PENGWIN 2024 Challenge*. IEEE Transactions on Medical Imaging, 45(5), 2212–2228. https://doi.org/10.1109/TMI.2025.3650126

Autores del model card

Estefanía Hernández, John David Franco, Mariana Cifuentes y Natalia Paredes.